Cahier des Charges Technique : Système de Détection d'Intrusion Réseau (NIDS) Intelligent pour Plateforme Logistique Industrielle

La sécurisation des flux de données au sein d'une plateforme de pilotage logistique industrielle, ou Supply Chain Control Tower (SCCT), représente un défi critique dans le paysage actuel de la transformation numérique. Une SCCT agit comme un centre d'intelligence centralisé, agrégeant des flux de données disparates provenant de systèmes ERP, WMS, TMS et de capteurs IoT pour offrir une visibilité de bout en bout sur le réseau d'approvisionnement.[1] Dans un environnement où 87 % des leaders de la supply chain considèrent le manque de visibilité en temps réel comme leur plus grand défi opérationnel, l'intégrité des API qui connectent ces systèmes est primordiale.[3] Ce rapport présente les spécifications techniques exhaustives pour un système de défense réseau intelligent (NIDS) découplé, conçu pour protéger les actifs logistiques contre les interruptions de service (DoS) et les exfiltrations de données (Exploits), en s'appuyant sur l'intelligence artificielle et le dataset de référence UNSW-NB15.

Analyse du Contexte et Besoins de Sécurité Logistique

La plateforme cible gère des flux critiques tels que les niveaux de stocks, la coordination des transporteurs et la planification des livraisons. La fragmentation des architectures technologiques modernes crée des "points aveugles" où des attaquants peuvent s'insérer pour perturber la chaîne de valeur.[2] Les interruptions de service, telles que les attaques par déni de service (DoS), peuvent paralyser la prise de décision proactive, transformant une gestion fluide en une "lutte contre l'incendie" réactive.[4] Parallèlement, le vol de données stratégiques par le biais d'exploits peut compromettre l'avantage concurrentiel d'une organisation en révélant ses structures de coûts ou ses relations avec les fournisseurs.[1]

Le choix du dataset UNSW-NB15 pour la conception de ce NIDS est dicté par sa modernité et sa capacité à refléter les comportements réseau réels et synthétiques contemporains. Contrairement au dataset KDD99, devenu obsolète en raison de sa distribution biaisée et de son âge, l'UNSW-NB15 a été créé à l'aide de l'outil IXIA PerfectStorm pour simuler une hybridation de trafic normal et de comportements d'attaque modernes.[6] Ce dataset contient neuf catégories d'attaques, offrant une base d'entraînement robuste pour identifier des menaces telles que les Fuzzers, les vers (Worms) ou les accès par porte dérobée (Backdoors).[6]

Attaque	Description Technique dans le Contexte Logistique	Impact sur la SCCT
DoS	Tentative de saturer les ressources d'une API de suivi de flotte.[9]	Perte de visibilité en temps réel sur les expéditions.
Exploit	Exploitation de vulnérabilités dans le protocole de communication ERP.[9]	Accès non autorisé aux bases de données de stocks.
Fuzzers	Envoi de données aléatoires pour faire planter un service API.[9]	Interruption des flux de commandes automatisés.
Reconnaissance	Collecte d'informations sur la structure du réseau logistique.[9]	Préparation d'une attaque ciblée de grande envergure.
Worms	Logiciels malveillants se propageant entre les systèmes partenaires.[9]	Infection massive du réseau de distribution.

Architecture Système : Découplage par le Modèle Sidecar

L'architecture proposée repose sur un découplage strict entre les fonctions métier logistiques (Module A) et le moteur de sécurité intelligent (Module B). Ce modèle, inspiré du pattern "Sidecar" utilisé dans les architectures de microservices, permet d'isoler la complexité de l'analyse par machine learning afin de ne pas impacter les performances de l'application principale.[10]

Module A : Interface Métier Logistique

Le Module A constitue le cœur opérationnel de la plateforme. Il expose des points de terminaison API pour le suivi des livraisons (/deliveries), la gestion des stocks et l'authentification des partenaires.[12] Pour chaque interaction réseau, le Module A extrait des métadonnées de flux sans interrompre le traitement de la requête utilisateur. Ces métadonnées incluent des variables telles que les adresses IP source et destination, les ports, la durée de la transaction et le volume d'octets échangés.[6] L'utilisation de FastAPI pour le développement de

ces modules est recommandée en raison de son support natif de la programmation asynchrone, permettant de maintenir une latence extrêmement faible lors de l'envoi des données au moteur de sécurité.[11]

Module B : Security Engine et Agent IA

Le Module B héberge la logique de détection d'intrusion. Il reçoit les métadonnées du Module A via une API REST sécurisée. Ce moteur fonctionne de manière asynchrone pour l'analyse continue, mais peut également opérer en mode bloquant pour les transactions à haut risque.[14] Le moteur intègre non seulement le modèle de détection mais aussi un Agent IA interactif chargé de l'explicabilité et de la recommandation stratégique. Cette séparation permet de mettre à jour les modèles de machine learning ou d'ajuster les seuils de détection sans avoir à redéployer l'interface métier logistique.[16]

Composant de l'Architecture	Technologie Recommandée	Rôle Clé
Serveur API	FastAPI + Uvicorn	Gestion asynchrone des flux et faible latence.[13]
Cache de Métadonnées	Redis	Stockage rapide pour le calcul des caractéristiques temporelles.[14]
Orchestration	Kubernetes (K8s)	Scalabilité horizontale des pods d'analyse ML.[13]
Conteneurisation	Docker	Isolation des environnements et reproductibilité.[13]

Analyse et Gestion de la Latence en Temps Réel

Dans une tour de contrôle logistique, chaque milliseconde compte pour garantir que les alertes de perturbation parviennent aux gestionnaires avant que les problèmes ne s'aggravent.[4] Pour maintenir une latence sous le seuil critique de 50 ms, plusieurs optimisations sont impératives. L'utilisation du pattern Sidecar permet de placer le moteur de sécurité sur le même hôte que l'application métier, réduisant les sauts réseau à une communication par localhost.[10] De plus, le chargement des modèles de machine learning en mémoire vive (RAM) via des singletons ou des caches lru_cache évite les temps de lecture disque lors de l'inférence.[14]

L'implémentation de gRPC au lieu de REST traditionnel pour les communications internes peut réduire davantage la latence grâce à l'utilisation de protocol buffers et du streaming

bidirectionnel.[10] Une architecture performante doit également intégrer une gestion intelligente des files d'attente, par exemple avec Celery ou Redis Streams, pour traiter les analyses lourdes en arrière-plan tout en renvoyant un verdict préliminaire rapide au Module A.[14]

Spécifications du Moteur de Machine Learning

Le moteur de machine learning doit relever le défi de la haute dimensionnalité et du déséquilibre des classes, tout en garantissant une détection précise des attaques connues et inconnues. L'approche retenue s'inspire des meilleures pratiques des compétitions de data science, combinant ingénierie de données avancée, modèles d'ensemble et deep learning.[19]

Ingénierie des Données et Réduction de Dimensionnalité

Le dataset UNSW-NB15 souffre d'un déséquilibre marqué, où le trafic normal représente la grande majorité des enregistrements, tandis que certaines attaques comme les "Worms" sont extrêmement rares.[9] L'application de la technique SMOTE (Synthetic Minority Over-sampling Technique) est essentielle pour équilibrer les classes en créant des exemples synthétiques pour les attaques minoritaires par interpolation entre les voisins les plus proches.[22] Cependant, SMOTE doit être utilisé avec prudence : il ne doit être appliqué que sur les données d'entraînement pour éviter les fuites de données (data leakage) qui gonfleraient artificiellement les métriques de test.[22]

Pour optimiser la vitesse d'inférence, une réduction de la dimensionnalité est opérée via l'élimination récursive des caractéristiques (RFE - Recursive Feature Elimination). En utilisant un classifieur Random Forest comme estimateur, la méthode RFE permet d'identifier un sous-ensemble de 15 à 20 variables conservant 95 % de la variance du dataset original.[25]

Variable Clé (RFE)	Type	Importance Statistique
sttl	Numérique	Corrélation élevée avec le saut réseau et la topologie de l'attaque.[25]
sbytes	Numérique	Volume de données envoyé par la source, critique pour les exploits.[25]
sload	Numérique	Charge de la source, indicateur de saturation pour les attaques DoS.[25]
dur	Numérique	Durée de la transaction,

		différencie les requêtes normales des scans.[6]
ct_dst_src_ltm	Numérique	Nombre de connexions similaires, détecte les comportements répétitifs.[25]

Certaines variables comme les adresses IP (srcip, dstip) ou les horodatages (stime, ltime) doivent être exclues du processus d'entraînement pour éviter que le modèle n'apprenne des biais liés à l'infrastructure spécifique du testbed ou à des moments temporels précis, ce qui nuirait à sa capacité de généralisation.[26]

Modèle Hybrid Ensemble (Stacking)

La détection des attaques connues repose sur un Voting Classifier organisé en structure de "Stacking". Cette approche combine plusieurs "weak learners" pour créer un modèle plus robuste et stable.[19]

Le modèle comprend trois algorithmes de base :

1. **LightGBM :** Apprécié pour sa vitesse d'entraînement et sa faible consommation de mémoire, il traite efficacement les grandes quantités de données tabulaires du réseau.[20]
2. **XGBoost :** Fournit une précision de pointe grâce à son implémentation du gradient boosting avec régularisation, minimisant les erreurs de prédiction.[20]
3. **Random Forest :** Un ensemble d'arbres de décision qui apporte une diversité structurelle et gère bien les relations non linéaires.[28]

Le méta-classifieur, souvent une régression logistique ou un perceptron multicouche (MLP), agrège les prédictions de ces trois modèles pour délivrer le verdict final : Autoriser ou Bloquer.[19] Les recherches montrent que cette fusion permet d'atteindre une précision supérieure à 98 % sur le dataset UNSW-NB15.[20]

Auto-encodeur pour la Détection des Attaques Zero-day

Les attaques "Zero-day", exploitant des vulnérabilités inconnues, ne peuvent être détectées par des modèles entraînés uniquement sur des signatures existantes. Un Auto-encodeur (Deep Learning) est utilisé ici comme moteur de détection d'anomalies non supervisé.[31]

Le modèle est entraîné exclusivement sur du trafic "normal" de l'application logistique. Il apprend à compresser les données d'entrée dans un espace latent réduit (bottleneck) puis à les reconstruire à l'identique.[31] Lorsqu'une attaque inconnue survient, ses caractéristiques divergent du profil normal appris, entraînant une erreur de reconstruction élevée.

$$\text{Erreur de Reconstruction} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \hat{x}_i)^2$$

Si cette erreur dépasse un seuil prédéfini (par exemple, le 95ème centile de l'erreur sur le trafic normal), le système lève une alerte d'anomalie.[31] L'architecture optimisée pour ce DAE (Denoising Autoencoder) comprend des couches denses de 64 unités, un goulot d'étranglement de 16 unités et l'ajout d'un bruit gaussien en entrée pour améliorer la robustesse des représentations apprises.[31]

Explicabilité avec SHAP (XAI)

L'explicabilité est cruciale pour que l'administrateur système puisse faire confiance aux décisions de l'IA. L'intégration de SHAP (SHapley Additive exPlanations), basée sur la théorie des jeux, permet d'attribuer à chaque caractéristique réseau une valeur de contribution positive ou négative à la décision de blocage.[33] En temps réel, SHAP identifie les variables qui ont déclenché l'alerte, transformant une prédiction "boîte noire" en une preuve technique tangible.[35]

Module d'Agent IA et Interface d'Administration

L'interface d'administration, développée avec Streamlit, centralise la surveillance et la gestion des incidents. Elle est conçue pour transformer des données techniques complexes en informations actionnables pour les opérateurs logistiques et les experts en sécurité.[17]

Dashboard en Temps Réel

Le dashboard affiche une visualisation dynamique du trafic réseau. Il met en évidence les scores de risque globaux et segmente le trafic par type d'application (ERP, WMS, API partenaires). Des graphiques interactifs permettent de forer dans les données pour examiner des périodes de temps spécifiques ou des segments de réseau particuliers.[35]

Agent IA Interactif et Analyse d'Incident

Pour chaque anomalie détectée, l'Agent IA génère une analyse textuelle structurée. Contrairement aux systèmes d'alerte classiques qui ne fournissent qu'un code d'erreur, cet agent utilise le contexte des données pour expliquer l'incident.[37]

1. **Nature de l'Attaque :** L'agent identifie la catégorie probable, par exemple : "Tentative de Reconnaissance détectée".
2. **Preuves Techniques :** L'IA extrait les faits marquants : "Le taux de paquets source (Spkts) est 15 fois supérieur à la moyenne historique de ce point de terminaison. La durée des connexions est inhabituellement courte (moins de 0.01s), suggérant un scan automatisé.".[37]
3. **Conseil Stratégique :** "Action recommandée : Bannissement temporaire (30 min) de

l'adresse IP source 192.168.x.x et examen des journaux d'accès du serveur API /auth/login.".[37]

Cette approche permet de combler le fossé entre la détection probabiliste de l'IA et la prise de décision déterministe humaine, améliorant ainsi la rapidité de réponse face aux menaces.[38]

Workflow de Décision et Rapports Automatisés

L'administrateur dispose de boutons d'action rapide intégrés à l'interface pour confirmer le blocage, ignorer l'alerte (faux positif) ou demander une analyse plus approfondie. Une fonctionnalité essentielle est la génération de rapports d'incidents automatisés au format LaTeX/PDF via la bibliothèque PyLaTeX.[40] Ces rapports sont structurés pour inclure :

- L'ID de l'incident et l'horodatage.
- Le résumé de l'impact métier (ex: interruption potentielle des flux de transport).
- L'évidence technique détaillée et les graphiques d'explicabilité SHAP.
- Les actions entreprises et les recommandations pour prévenir la récurrence.[42]

Plan de Test et Stratégie de Validation

Un NIDS n'est efficace que s'il peut démontrer sa fiabilité à travers des tests rigoureux. Le plan de test se concentre sur l'équilibre entre la détection des menaces et la continuité des opérations métiers.

Métriques de Performance du Modèle

L'évaluation ne peut se limiter à la simple précision globale (accuracy), surtout sur des datasets déséquilibrés. Les métriques suivantes sont prioritaires :

- **Précision (Precision) :** Pourcentage d'alertes qui sont de véritables attaques. Une précision élevée réduit la fatigue des alertes pour les administrateurs.[44]
- **Rappel (Recall) :** Capacité du modèle à détecter toutes les attaques présentes. Pour les exploits critiques, un rappel de plus de 98 % est visé.[44]
- **F1-Score :** Moyenne harmonique de la précision et du rappel, offrant une vue équilibrée de la performance sur les classes minoritaires.[44]
- **Taux de Faux Positifs (FPR) :** Crucial pour la logistique ; un FPR élevé bloquerait des camions ou des commandes légitimes.[44]

Objectif de Performance	Valeur Cible	Méthode de Validation
Précision Globale	> 98.5 %	Validation croisée 10-fold sur UNSW-NB15.[19]

Rappel (Catégorie DoS)	> 99.0 %	Test sur set de données DoS isolés.[20]
F1-Score (Catégorie Exploit)	> 95.0 %	Analyse par classe sur le set de test.[26]
Latence d'Inférence	< 120 ms	Tests de charge sous concurrent load.[11]

Stratégie de Mise à Jour et Boucle de Rétroaction

Le système intègre un mécanisme de "Human-in-the-Loop" (HITL) pour garantir une amélioration continue. Chaque action de l'administrateur (confirmation ou rejet d'une alerte) est enregistrée comme une nouvelle donnée d'entraînement étiquetée.[38]

1. **Collecte de Feedback :** Les erreurs du modèle (faux positifs identifiés par l'humain) sont stockées dans une base de données de rétroaction.[48]
2. **Surveillance de la Dérive (Drift) :** Des outils de monitoring analysent si les caractéristiques du trafic réseau évoluent au fil du temps (par exemple, suite à une mise à jour logicielle de la plateforme logistique).[48]
3. **Ré-entraînement Périodique :** Le modèle est ré-entraîné automatiquement ou semi-automatiquement sur une base mensuelle, intégrant les nouvelles données et les corrections humaines pour affiner ses frontières de décision.[48]
4. **Déploiement Canary :** Les nouveaux modèles sont d'abord déployés sur une petite fraction du trafic ou en mode "shadow" (prédictions enregistrées mais non appliquées) avant d'être généralisés.[16]

Cette approche garantit que le NIDS reste résilient face à l'évolution des cybermenaces et aux changements structurels de l'infrastructure logistique industrielle.[39]

Synthèse et Recommandations Opérationnelles

Le système de défense réseau intelligent présenté dans ce cahier des charges offre une protection multicouche adaptée aux exigences de la Supply Chain Control Tower moderne. En combinant la puissance des modèles d'ensemble pour les menaces connues et la flexibilité des auto-encodeurs pour l'inconnu, le NIDS assure une couverture exhaustive.

Recommandations pour l'Équipe de Développement

- **Prioriser l'Asynchronisme :** Toute la chaîne de traitement, de la capture des métadonnées dans le Module A à l'analyse SHAP dans le Module B, doit utiliser des bibliothèques asynchrones (FastAPI, Redis-py, Motor pour MongoDB) pour éviter les goulots d'étranglement.[11]
- **Sécuriser l'API de Sécurité :** La communication entre le Module A et le Module B doit

être protégée par OAuth2 ou JWT, et chiffrée via TLS, car elle transporte des métadonnées qui pourraient être utilisées par un attaquant pour comprendre les mécanismes de défense.[15]

- **Focus sur l'UI/UX :** Le dashboard Streamlit doit rester simple. Un excès d'informations techniques peut ralentir la réaction humaine en cas de crise. L'Agent IA doit être le point d'entrée privilégié pour comprendre l'urgence d'une situation.[35]
- **Monitoring de l'Infrastructure :** Outre la performance du modèle ML, l'état de santé des conteneurs et la latence réseau entre les modules doivent être surveillés en permanence avec des outils comme Prometheus et Grafana.[13]

En mettant en œuvre ce cahier des charges, l'organisation se dote d'un bouclier intelligent capable non seulement de détecter les intrusions, mais aussi d'évoluer avec les menaces, garantissant ainsi la continuité et la sécurité de sa chaîne d'approvisionnement globale.[2]

Sources des citations

1. What is a Supply Chain Control Tower? - IBM, consulté le avril 23, 2026, https://www.ibm.com/think/topics/control-towers
2. What Is a Supply Chain Control Tower? The Benefits of AI-Driven Logistics - IQAX, consulté le avril 23, 2026, https://www.iqax.com/en/about/newsroom/2026/01/what-is-a-supply-chain-control-tower/
3. Supply Chain Control Tower: How to Build Real-Time Logistics Visibility That Delivers ROI, consulté le avril 23, 2026, https://locus.sh/blogs/supply-chain-control-tower-real-time-visibility/
4. Supply Chain Control Tower Explained: Use Cases & Benefits - Locus, consulté le avril 23, 2026, https://locus.sh/blogs/supply-chain-control-tower/
5. Purpose of a Supply Chain Tower in Logistics | Epicor UK, consulté le avril 23, 2026, https://www.epicor.com/en-gb/blog/supply-chain-management/what-is-a-supply-chain-tower/
6. UNSW_NB15 - Kaggle, consulté le avril 23, 2026, https://www.kaggle.com/datasets/mrwellsdavid/unsw-nb15
7. Classification of UNSW-NB15 dataset using Exploratory Data Analysis using Ensemble Learning - Semantic Scholar, consulté le avril 23, 2026, https://pdfs.semanticscholar.org/020e/47550771cbf27aad5b5943da9ec4b32a717d.pdf
8. UNSW-NB15, consulté le avril 23, 2026, https://fkie-cad.github.io/COMIDDS/content/datasets/unsw_nb15/
9. CIC UNSW-NB15 Augmented Dataset - University of New Brunswick, consulté le avril 23, 2026, https://www.unb.ca/cic/datasets/cic-unsw-nb15.html
10. Reducing Latency with Sidecar. How the sidecar pattern helped in ..., consulté le avril 23, 2026, https://medium.com/gojekengineering/reducing-latency-with-sidecar-cdb09705cc2

7
11. AI-Driven Real-Time API Security: Explainable Threat Detection for Cloud Environments - TechRxiv, consulté le avril 23, 2026, https://www.techrxiv.org/doi/pdf/10.36227/techrxiv.175695570.09221013/v1?onload=true
12. How I Documented My Endpoint API Using OpenAPI Spec Generator and GitBook - Medium, consulté le avril 23, 2026, https://medium.com/@iniwillie10/how-i-documented-my-endpoint-api-using-openapi-spec-generator-and-gitbook-e883df550fa3
13. 7 FastAPI Deployment Patterns That Keep Latency Under 50ms | by Hash Block - Medium, consulté le avril 23, 2026, https://medium.com/@connect.hashblock/7-fastapi-deployment-patterns-that-keep-latency-under-50ms-1b6cb4814a23
14. Building Real-Time ML Inference Pipelines with FastAPI and Redis | by Om Sai Krishna Madhav Lella | Medium, consulté le avril 23, 2026, https://medium.com/@omsaikrishnamadhav.lella/building-real-time-ml-inference-pipelines-with-fastapi-and-redis-073a6b8d5b01
15. Scalable and Secure AI Inference in Healthcare: A Comparative Benchmarking of FastAPI and Triton Inference Server on Kubernetes - arXiv, consulté le avril 23, 2026, https://arxiv.org/html/2602.00053v1
16. FastAPI for MLOps: Python Project Structure and API Best Practices - PyImageSearch, consulté le avril 23, 2026, https://pyimagesearch.com/2026/04/13/fastapi-for-mlops-python-project-structure-and-api-best-practices/
17. How to Use FastAPI for Machine Learning | The PyCharm Blog, consulté le avril 23, 2026, https://blog.jetbrains.com/pycharm/2024/09/how-to-use-fastapi-for-machine-learning/
18. FerrariDG/async-ml-inference: PoC with FastAPI and Celery to ML inference - GitHub, consulté le avril 23, 2026, https://github.com/FerrariDG/async-ml-inference
19. Hybrid Stacking Model for Web Attack Classification Using LightGBM, Random Forest, and MLP | CommIT (Communication and Information Technology) Journal, consulté le avril 23, 2026, https://journal.binus.ac.id/index.php/commit/article/view/13718
20. View of Enhancing Intrusion Detection Systems with Ensemble Models and Hybrid Feature Selection Techniques, consulté le avril 23, 2026, https://jisem-journal.com/index.php/journal/article/view/3816/1678
21. The UNSW-NB15 Dataset, consulté le avril 23, 2026, https://research.unsw.edu.au/projects/unsw-nb15-dataset
22. Why Most People Misuse SMOTE, And How to Do It Right - KDnuggets, consulté le avril 23, 2026, https://www.kdnuggets.com/why-most-people-misuse-smote-and-how-to-do-it-right
23. SMOTE: How to Fix Imbalanced Data in Machine Learning - Lyzr AI, consulté le

avril 23, 2026, https://www.lyzr.ai/blog/smote-imbalanced-data-machine-learning/
24. The right way of using SMOTE with Cross-validation | by KSV Muralidhar - Medium, consulté le avril 23, 2026, https://medium.com/data-science/the-right-way-of-using-smote-with-cross-validation-92a8d09d00c7
25. UNSW-NB15 dataset feature selection and network intrusion detection using deep learning, consulté le avril 23, 2026, https://www.researchgate.net/publication/332265020_UNSW-NB15_dataset_feature_selection_and_network_intrusion_detection_using_deep_learning
26. Recursive Feature Elimination with Cross-Validation with Decision ..., consulté le avril 23, 2026, https://www.mdpi.com/2224-2708/12/5/67
27. A Multiclass Network Intrusion Detection System Using Stacking Ensemble Technique with Hybrid Feature Selection - Journal of Advances in Information Technology, consulté le avril 23, 2026, https://www.jait.us/articles/2025/JAIT-V16N3-342.pdf
28. Enhancing Intrusion Detection Systems with Ensemble Models and Hybrid Feature Selection Techniques - ResearchGate, consulté le avril 23, 2026, https://www.researchgate.net/publication/390196558_Enhancing_Intrusion_Detection_Systems_with_Ensemble_Models_and_Hybrid_Feature_Selection_Techniques
29. Machine learning-based network intrusion detection for big and imbalanced data using oversampling, stacking feature embedding and feature extraction - arXiv, consulté le avril 23, 2026, https://arxiv.org/html/2401.12262v1
30. Enhanced Intrusion Detection Systems Performance with UNSW-NB15 Data Analysis - BCU Open Access Repository - Birmingham City University, consulté le avril 23, 2026, https://www.open-access.bcu.ac.uk/15332/1/algorithms-17-00064.pdf
31. A Guide to Zero-Day Attack Detection with Denoising Autoencoders, consulté le avril 23, 2026, https://www.analyticsvidhya.com/blog/2025/09/zero-day-attack-detection/
32. Zero-Day Attack Detection System Using Autoencoders and Isolation Forest An Unsupervised Machine Learning Approach | PDF - Scribd, consulté le avril 23, 2026, https://www.scribd.com/document/989209694/Zero-Day-Attack-Detection-System-Using-Autoencoders-and-Isolation-Forest-an-Unsupervised-Machine-Learning-Approach
33. Detecting Cybersecurity Threats by Integrating Explainable AI with SHAP Interpretability and Strategic Data Sampling - arXiv, consulté le avril 23, 2026, https://arxiv.org/html/2602.19087v1
34. Explainable AI, consulté le avril 23, 2026, https://shap-app.streamlit.app/
35. Stop Making Boring SHAP Plots. Build an Interactive AI “Mind ..., consulté le avril 23, 2026, https://medium.com/data-science-collective/stop-making-boring-shap-plots-build-an-interactive-ai-mind-reading-dashboard-instead-8f112ff7048b
36. RodrigoGonzalez/streamlit-shap-app: This app demonstrates how to use the

SHAP library to explain models. - GitHub, consulté le avril 23, 2026, https://github.com/RodrigoGonzalez/streamlit-shap-app
37. The AI Incident Report Template I Actually Use for Wrong Answers and Tool Failures, consulté le avril 23, 2026, https://dev.to/optyxstack/the-ai-incident-report-template-i-actually-use-for-wrong-answers-and-tool-failures-174l
38. What Is Human In The Loop (HITL)? - IBM, consulté le avril 23, 2026, https://www.ibm.com/think/topics/human-in-the-loop
39. Human-in-the-Loop: The Architecture Pattern Behind Reliable AI | by Shankar Jadhav | Medium, consulté le avril 23, 2026, https://medium.com/@shankarjadhav4177/human-in-the-loop-the-architecture-pattern-behind-reliable-ai-4924a48ed683
40. PyLaTeX 1.4.2 documentation - GitHub Pages, consulté le avril 23, 2026, https://jeltef.github.io/PyLaTeX/current/
41. Generating pdf-latex with python script - Stack Overflow, consulté le avril 23, 2026, https://stackoverflow.com/questions/8085520/generating-pdf-latex-with-python-script
42. Penetration Test Report Template - Overleaf, Online LaTeX Editor, consulté le avril 23, 2026, https://www.overleaf.com/latex/templates/penetration-test-report-template/khgrjvgfsjqg
43. Security Incident Report Template Download for free - BIZOPS-7 - TrustCommunity, consulté le avril 23, 2026, https://community.trustcloud.ai/docs/trustops/helpful-resources/documentation-templates/security-incident-report-template/
44. Classification: Accuracy, recall, precision, and related metrics | Machine Learning, consulté le avril 23, 2026, https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall
45. F1 Score in Machine Learning Explained | Encord, consulté le avril 23, 2026, https://encord.com/blog/f1-score-in-machine-learning/
46. Performance Metrics: Confusion matrix, Precision, Recall, and F1 Score, consulté le avril 23, 2026, https://towardsdatascience.com/performance-metrics-confusion-matrix-precision-recall-and-f1-score-a8fe076a2262/
47. What Is Accuracy, Precision, Recall, and F1 Score? - labelf.ai, consulté le avril 23, 2026, https://labelf.ai/blog/what-is-accuracy-precision-recall-and-f1-score
48. How Feedback Loops in Human-in-the-Loop AI Improve Model ..., consulté le avril 23, 2026, https://www.nextwealth.com/blog/how-feedback-loops-in-human-in-the-loop-ai-improve-model-accuracy-over-time/
49. Operationalizing the R4VR-Framework: Safe Human-in-the-Loop Machine Learning for Image Recognition - MDPI, consulté le avril 23, 2026, https://www.mdpi.com/2227-9717/13/12/4086

50. HUMAN-IN-THE-LOOP FOR MACHINE LEARNING IN OFFENSIVE CYBERSECURITY, consulté le avril 23, 2026, https://www.jaist.ac.jp/~razvan/publications/human_in_the_loop_offensive_cybersecurity.pdf
51. Supply Chain Visibility in Logistics: Control & Monitoring Guide - Orderful, consulté le avril 23, 2026, https://www.orderful.com/blog/supply-chain-management-logistics